5.3 非光滑问题下的梯度方法

Def 5.4 Lipschitz连续函数，称一个函数 Lipschitz，就是

$|F(\eta) - F(\theta)| \leq B\|\eta-\theta\|_2$

对于可微函数，B-Lipschitz 等价于导数二范数有界

中值定理 $|F(\eta) - F(\theta)| = |F'(\xi)^T(\eta-\theta)| \leq \|F'(\xi)\| \cdot \|\eta-\theta\|$

反之，如果有 $\|F'(\theta)\| > B$，那么由连续性，∃ $B(\theta, \delta)$，$\forall \eta, \xi \in B(\theta,\delta)$ $\|F'(\xi)\| > B$

$|F(\eta) - F(\theta)| > B \cdot \|\eta-\theta\|$

不可微情景，构造次梯度

$F(y) \geq F(x) + z^T(y-x)$，称 z 为 $\partial F(x)$ 的一个次微分

若 F 凸且可微，那么 $\partial F(x) = \{F'(x)\}$，证明如

$F(y) \geq F(x) + F'(x)^T(y-x)$ （凸可微函数的定义）$\forall y \in \mathcal{X}$

$F(x+tu) \leq tF(y) + (1-t)F(x)$ $\quad \dfrac{F(x+tu)-F(x)}{t}$ $\quad F(y) - F(x) \geq \dfrac{F(x+tu)-F(x)}{t}$

$F(y) - F(x) \geq F'(x)^T(y-x)$

反之，若 g 为一个次梯度

$$F(x+tv)-F(x) \ge t\langle g, v\rangle \xrightarrow{t\to 0} \langle F'(x), v\rangle \ge \langle g, v\rangle$$

令 $v=-v$ $\quad \langle F'(x), -v\rangle \ge \langle g, -v\rangle \quad \langle F'(x), v\rangle \le \langle g, v\rangle$

$F' = g$

$$\theta \to |\theta| \qquad \partial|\theta| = \begin{cases} 1 \\ [-1,1] \\ -1 \end{cases}$$

$\theta \to (1-y\theta^T x)_+$

当 $1-y\theta^T x > 0$ $\quad \partial(1-y\theta^T x) = \{-yx\}$

$1-y\theta^T x < 0 \quad \partial f(\theta) = \{0\}$

$1-y\theta^T x = 0 \quad \partial f(\theta) = \{-\alpha y x\}$

$$\underbrace{(1-y\theta^T x)}_{F(\theta)} - \underbrace{0}_{F(\theta_0)\,=\,(1-y\theta_0^T x)} \ge \langle g, \theta-\theta_0\rangle$$

$\cancel{\alpha}\langle -yx, \theta-\theta_0\rangle \ge \langle g, \theta-\theta_0\rangle$

$g = \{-kyx \mid k \cancel{\in[2,1]}\}$ $\quad k$

$h(u)=\max\{0,u\} \qquad \partial h(u) = \begin{cases} \{1\}, & u>0 \\ [0,1], & u=0 \\ \{0\}, & u<0 \end{cases}$

那么 $\partial(1-y\theta^T x)_+ = \begin{cases} \{-yx\} & y\theta^T x < 1 \\ \{-\alpha y x\} \quad \alpha\in[0,1] & y\theta^T x = 1 \\ \{0\} & y\theta^T x > 1 \end{cases}$

次梯度方法的收敛性：

F is convex, B-Lipschitz连续（某种意义上的"导数有界"），$\|\eta_* - \theta_0\| \le D$

$\gamma_t = \frac{D}{B\sqrt{t}}$，学习率按 $\frac{1}{\sqrt{t}}$ 速度衰减，使用次梯度来下降

证明，与SGD类似 $\theta_t = \theta_{t-1} - \gamma_t g_{t-1}$，$g_{t-1}$ 是一个次梯度

$\|\theta_t - \eta_*\|_2^2 = \|\theta_{t-1} - \gamma_t g_t - \eta_*\|_2^2 = \|\theta_{t-1} - \eta_*\|_2^2 - 2\gamma_t \langle g_t, \theta_{t-1} - \eta_* \rangle + \gamma_t^2 \|g_t\|_2^2$

$+ \langle g_t, \theta_{t-1} - \eta_* \rangle \overset{\ge}{\le} F(\theta_{t-1}) - F(\eta_*)$

$\cancel{\text{又}}$ $F(\eta_*) - F(\theta_{t-1}) \ge \langle g_t, \eta_* - \theta_{t-1} \rangle$

$\cancel{2\gamma_t (F(\eta}$ $2\gamma_t (F(\theta_{t-1}) - F(\eta_*)) \le \|\theta_{t-1} - \eta_*\|_2^2 - \|\theta_t - \eta_*\|_2^2 + \gamma_t^2 \|g_t\|_2^2$

$\sum_{t=1}^{T} \gamma_t (F(\theta_{t-1}) - F(\eta_*)) \le \|\theta_0 - \eta_*\|_2^2 - \|\theta_T - \eta_*\|_2^2 + \sum_{t=1}^{T} \gamma_t^2 \|g_t\|_2^2$

$\cancel{F(\theta_t)}$ F

$\min_{0 \le s \le t-1} (F(\theta_{t-1}) - F(\eta_*)) \le \frac{1}{2}\left(\frac{\|\theta_0 - \eta_*\|_2^2}{\sum_{s=1}^{t} \gamma_s} + \frac{\sum_{s=1}^{t} \gamma_s^2}{\sum_{s=1}^{t} \gamma_s} B^2 \right) = \frac{D^2}{2\sum_{s=1}^{t} \gamma_s} + \frac{\sum_{s=1}^{t} \gamma_s^2}{2\sum_{s=1}^{t} \gamma_s} B^2$

$\sum_{s=1}^{t} \gamma_s \ge \frac{D}{B} \sqrt{t}$ $\quad \sum \gamma_t^2 \le \frac{D^2}{B^2} \sum \frac{1}{t} \le \frac{D^2}{B^2}(1 + \log t)$

原式 $\le \frac{BD}{2\sqrt{t}} + \frac{BD(1+\log t)}{2\sqrt{t}}$

Ex 5.20

如果 $\theta_t = \theta_{t-1} - \frac{\gamma_t'}{\|F'(\theta_{t-1})\|_2} F'(\theta_{t-1})$ $\quad \gamma_t = \frac{D}{\sqrt{t}}$，这样我们不需要已知B，只用知道有界即可

结论是，依然可以被 $\frac{BD(2+\log t)}{2\sqrt{t}}$ 控制，记 $F'(\theta_{t-1}) = \cancel{g_{t-1}}\, g_t$

$\|\theta_t - \eta_*\|_2^2 = \|\theta_{t-1} - \eta_*\|_2^2 - 2\frac{\gamma_t'}{\cancel{\|F'(\theta_{t-1})\|}} \langle g_t, \theta_{t-1} \rangle \frac{1}{\|g_t\|} + (\gamma_t')^2.$

$\cancel{2\gamma}$ $2\gamma_t'(F(\theta_{t-1}) - F(\eta_*)) \le \|g_t\| [\|\theta_{t-1} - \eta_*\|_2^2 - \|\theta_t - \eta_*\|_2^2 + (\gamma_t')^2] \le DB(\|\theta_{t-1}\| - \|\theta_{t-1}\|$

$\sum_{s=1}^{t} \frac{D}{\sqrt{s}}$ $\quad 2\min_{0 \le s \le t-1} (F(\theta_s) - F(\eta_*)) \le BD^2 (1 + \sum_{s=1}^{t} \frac{1}{t}) \le BD^2(2 + \log t)$ $\quad + \frac{D^2}{t}$

$2D\sqrt{t} \min (F(\theta_s) - F(\eta_*)) \le BD^2 (2 + \log t)$

Ex5.21 考虑一个凸集 $K\subset\mathbb{R}^n$，并且构造一个投影算子 Π_K

$\Pi_K(\theta)=\underset{\eta\in K}{\arg\min}\|\eta-\theta\|_2^2$，说明投影算子是一个压缩映射，即 $\|\Pi_K(\eta)-\Pi_K(\theta)\|_2$

$\theta_t=\Pi_K(\theta_{t-1}-\gamma_t F(\theta_{t-1}))$，$\eta_*$ 为F在K上的最小值，

按这种迭代法，$\min_{0\le s\le t-1} F(\theta_s)-F(\eta_*)\le DB\frac{2+\log t}{2\sqrt{t}}$

~~$\|\theta_t-\theta\eta_*\|=\|\Pi_K$~~

投影 证 $p=\Pi_K(x)$ ~~$p_t=tz+(1-t)p$~~ $\forall z\in K$

$p_t=tz+(1-t)p$ $\varphi(t)=\|p_t-x\|_2^2$

由于 $t=0$ 为 $\varphi(t)$ 最小值，$\varphi(t)=\|p-x+t(z-p)\|_2^2=\|p-x\|^2$

$\varphi'(0)=\langle p-x,z-p\rangle\ge0$ $\langle x-p,z-p\rangle\le0$

同理 $q=\Pi_K(y)$，满足 $\langle y-q,z-q\rangle\le0$ $\forall z\in K$

$\langle x-p,q-p\rangle\le0$

$\langle y-q,p-q\rangle\le0$

$\langle x-y-(p-q),q-p\rangle\le0$ $\langle x-y,p-q\rangle\ge\langle p-q,p-q\rangle$

$\|p-q\|\|x-y\|\ge\|p-q\|^2$ $\|p-q\|\le\|x-y\|$.

接下来，证明投影情况下依然满足收敛性

$\|\theta_t-\eta_*\|=\|\Pi_K(\theta_{t-1}-\gamma_tF'(\theta_{t-1}))-\Pi_K(\eta_*)\|\le\|\theta_{t-1}-\gamma_tF'(\theta_{t-1})-\eta_*\|$

接下来证明过程与次梯度证明方法相似

形式完全一致